Análise da influência da renda familiar na evasão de alunos no Instituto Federal de Educação, Ciência e Tecnologia de São Paulo

Tópico: Análise de Dados Visual (Visual Analytics)

Professora: Wu, Shin - Ting

Alunos:
Luiz Roberto Albano Junior
Faculdade de Engenharia Elétrica e de Computação
Universidade Estadual de Campinas
Campinas, Brasil
l272746@g.unicamp.br

Tárcio Augusto Canhamina Quissanga
Faculdade de Engenharia Elétrica e de Computação
Universidade Estadual de Campinas
Campinas, Brasil
t214551@dac.unicamp.br

---

1. PROJETO

Este projeto tem por objetivo realizar uma análise sobre o **nível de evasão dos alunos no IFSP - Instituto Federal de São Paulo** e confirmar se este dado **não é influenciado pela renda familiar** (H0).

Estátisticas de teste: nível de evasão de alunos

1.1. Base de Dados

Para construção deste projeto serão analisados os **micro dados** da **Plataforma Nilo Peçanha (PNP)** [1]. Segundo descrição do site:

> "A Plataforma Nilo Peçanha (PNP) é um ambiente virtual de coleta, validação e disseminação das estatísticas oficiais da Rede Federal de Educação Profissional, Científica e Tecnológica (Rede Federal). Tem como objetivo reunir dados relativos ao corpo docente, discente, técnico-administrativo e de gastos financeiros das unidades da Rede Federal, para fins de cálculo dos indicadores de gestão monitorados pela Secretaria de Educação Profissional e Tecnológica do Ministério da Educação (SETEC/MEC)."

Para o projeto selecionamos a base de dados referente aos **microdados de matrículas do ano base de 2020** [2].

```
import pandas as pd
import numpy as np
from plotnine import *
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.utils import resample
from scipy.stats import ttest_ind, mannwhitneyu, chi2_contingency
import statsmodels.api as sm
import statsmodels.formula.api as smf
```

```
#Download da base de dados
!wget https://github.com/prof-LuizAlbano/feec-analise-dados-visual/raw/main/Tarefas/ProjetoFinal/BaseDados/microdados_matric
```

```
--2024-07-04 01:46:13--  https://github.com/prof-LuizAlbano/feec-analise-dados-visual/raw/main/Tarefas/ProjetoFinal/Base
Resolving github.com (github.com)... 140.82.112.4
Connecting to github.com (github.com)|140.82.112.4|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/prof-LuizAlbano/feec-analise-dados-visual/main/Tarefas/ProjetoFinal/BaseDado
--2024-07-04 01:46:13--  https://raw.githubusercontent.com/prof-LuizAlbano/feec-analise-dados-visual/main/Tarefas/Projet
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, 185.199.109.133, 185.199.110.133, ..
Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 56492054 (54M) [application/zip]
Saving to: ‘microdados_matriculas_2021.zip’

microdados_matricul 100%[===================>]  53.88M  89.2MB/s    in 0.6s
```

```
2024-07-04 01:46:14 (89.2 MB/s) - 'microdados_matriculas_2021.zip' saved [56492054/56492054]
```

```
#Descompactação do arquivo
!unzip microdados_matriculas_2021.zip
```

```
Archive:  microdados_matriculas_2021.zip
  inflating: microdados_matriculas_2021.csv
```

```
#Leitura da Base de dados dos Microdados Matriculados até 2019, fornecido pelo MEC

df = pd.read_csv('microdados_matriculas_2021.csv', sep=';', low_memory=False)
#df.head()

#Conhecendo a forma (tamanho da dataset), vendo o volume de dados com as quais estaremos trabalhando para a nossa análise e
df.shape
#df.columns
```

```
(1507476, 54)
```

```
#Fazendo uma extração do Dataset geral somente as colunas que nos dariam os dados que interessariam para o nosso estudo
studyColumns = ['Cor/Raça', 'Eixo Tecnológico', 'Faixa Etária', 'Fator Esforco Curso', 'Fonte de Financiamento', 'Idade', 'I
df = df[studyColumns]
df.head()
df.shape
```

```
(1507476, 18)
```

2. LIMPEZA E PREPARAÇÃO DOS DADOS

```
# 2.1. Verificando dados em falta
print(df.isnull().sum())
```

```
Cor/Raça                       0
Eixo Tecnológico               0
Faixa Etária                   0
Fator Esforco Curso            0
Fonte de Financiamento         0
Idade                       3784
Instituição                    0
Modalidade de Ensino           0
Código do Município com DV     0
Nome de Curso                  0
Região                         0
Renda Familiar                 0
Sexo                           0
Situação de Matrícula          0
Tipo de Curso                  0
Turno                          0
UF                             0
Unidade de Ensino              0
dtype: int64
```

```
# 2.2. Removendo linhas com dados em falta
df_cleaned = df.dropna()
df_cleaned.shape
```

```
(1503692, 18)
```

```
# 2.3. Converter tipo de dado
df_cleaned['Idade'] = df_cleaned['Idade'].astype(int)
```

```
<ipython-input-8-c4e19065277c>:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-
```

```
#Verificando os dados

#Renda Familiar
print(df_cleaned['Renda Familiar'].unique())
```

```
['1<RFP<=1,5' 'RFP>3,5' '0<RFP<=0,5' '1,5<RFP<=2,5' '2,5<RFP<=3,5'
 'Não declarada' '0,5<RFP<=1']
```

```
#Situação de Matrícula
situacoes_matricula = df_cleaned['Situação de Matrícula'].unique()
situacoes_matricula
```

```
array(['Integralizada', 'Concluída', 'Abandono', 'Em curso', 'Desligada',
       'Cancelada', 'Transf. externa', 'Transf. interna', 'Reprovado'],
      dtype=object)
```

```
#Instituições
instituicoes = df_cleaned['Instituição'].unique()
instituicoes
```

```
array(['IFG', 'IF GOIANO', 'IFMT', 'IFB', 'IFMS', 'IFPB', 'UFPB - CAVN',
       'IFS', 'IFPE', 'IFBA', 'IFMA', 'IFCE', 'IFAL', 'IF BAIANO',
       'UFCG - ETSC', 'IFRN', 'IF SERTÃO-PE', 'IFPI', 'UFPB - ETS',
       'ESUFRN', 'UFPI - CABJ', 'UFMA - COLUN', 'IFTO', 'IFRO', 'IFAM',
       'IFAP', 'IFRR', 'IFAC', 'IFPA', 'EMUFPA', 'IFMG', 'IFES', 'IFF',
       'IFSP', 'CEFET-MG', 'CEFET-RJ', 'IF SUDESTE MG', 'IFSULDEMINAS',
       'IFRJ', 'IFNMG', 'CPII', 'IFTM', 'UFU - ESTES', 'UFTM - CEFORES',
       'UFV - CEDAF', 'IF FARROUPILHA', 'IFSUL', 'IFRS', 'IFC', 'IFSC',
       'IFPR', 'UFSM - POLITÉCNICO', 'UFRPE - CODAI', 'UFRN - EAJ',
       'UFSM - CTISM', 'UFPI - CTF', 'UFRN - MÚSICA', 'ETDUFPA',
       'UFMG - TU', 'UFRR - EAGRO', 'UFMG - COLTEC', 'UFPI - CAT',
       'UFAL - ETA', 'UFRRJ - CTUR'], dtype=object)
```

```
#Tipo de Curso
tipos_cursos = df_cleaned['Tipo de Curso'].unique()
tipos_cursos
```

```
array(['Técnico', 'Bacharelado', 'Tecnologia',
       'Qualificação Profissional (FIC)', 'Especialização (Lato Sensu)',
       'Mestrado Profissional', 'Mestrado', 'Ensino Fundamental II',
       'Ensino Médio', 'Licenciatura', 'Ensino Fundamental I',
       'Doutorado', 'Educação Infantil'], dtype=object)
```

```
#Faixa Etária
faixa_etaria = df_cleaned['Faixa Etária'].unique()
faixa_etaria
```

```
array(['15 a 19 anos', '20 a 24 anos', '25 a 29 anos', '30 a 34 anos',
       '35 a 39 anos', '50 a 54 anos', '45 a 49 anos', '40 a 44 anos',
       'Maior de 60 anos', '55 a 59 anos', 'Menor de 14 anos', 'S/I'],
      dtype=object)
```

```
#Cor/Raça
cor_raca = df_cleaned['Cor/Raça'].unique()
cor_raca
```

```
array(['BRANCA', 'INDÍGENA', 'NÃO DECLARADA', 'PARDA', 'PRETA', 'AMARELA'],
      dtype=object)
```

```
#Sexo
sexo = df_cleaned['Sexo'].unique()
sexo
```

```
array(['F', 'M'], dtype=object)
```

3. FILTROS E ANÁLISES INICIAIS DOS DADOS

3.1. ANÁLISE SOBRE OS DADOS GERAIS

No dataset estão contidos dados de toda rede federal, portanto para cumprirmos com o objetivo deste projeto iremos filtrar apenas os registros que se referem ao **IFSP - Instituto Federal de São Paulo**.

```
df_filtered = df_cleaned[ (df_cleaned['Instituição'] == "IFSP") ]
#df_filtered.head()
df_filtered.shape
```

```
(56473, 18)
```

Incialmente, vamos analisar alguns quantificadores por variáveis, para entender os dados do dataset.

```
#Matrículas por tipo de curso

(
    ggplot(df_filtered, aes(x="Tipo de Curso"))
    + geom_histogram(binwidth=0.5, show_legend=True)
    + labs(y="Matriculados")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

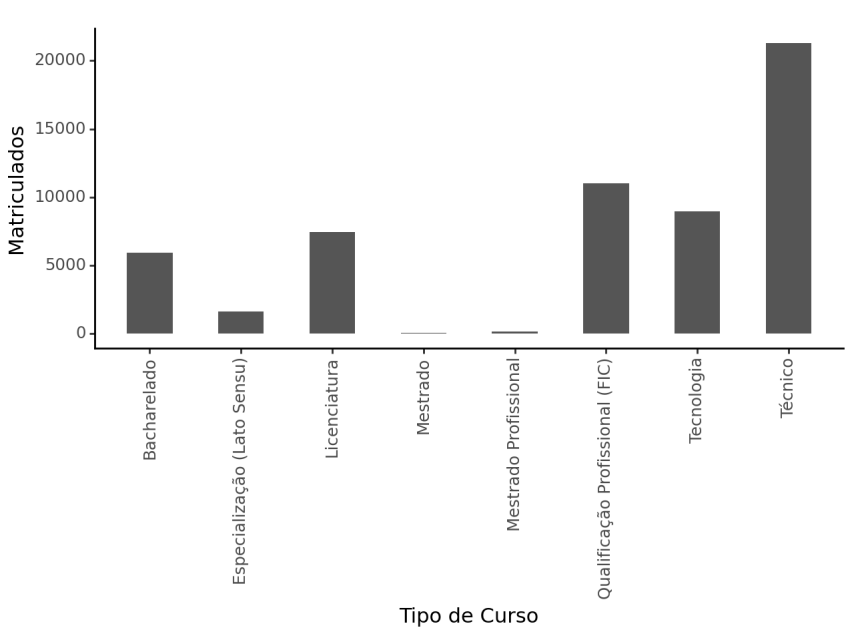


```
<Figure Size: (640 x 480)>
```

Por serem cursos de formação específicos e além do ciclo de formação de um estudante, vamos filtrar o dataset sem os dados dos cursos: Especialização, Mestrado, Mestrado Profissional e Qualificação Profissional (FIC).

```
df_filtered = df_filtered[ ~df_filtered['Tipo de Curso'].isin(['Mestrado', 'Mestrado Profissional', 'Especialização (Lato Se
df_filtered.shape
```

```
(43620, 18)
```

```
#Renda Familiar

renda_ordenada = ['0<RFP<=0,5', '0,5<RFP<=1', '1<RFP<=1,5', '1,5<RFP<=2,5', '2,5<RFP<=3,5', 'RFP>3,5', 'Não declarada']
df_filtered["Renda Familiar"] = df_filtered["Renda Familiar"].astype('category').cat.reorder_categories(renda_ordenada, orde

(
    ggplot(df_filtered, aes(x="Renda Familiar"))
    + geom_histogram(binwidth=0.5, show_legend=True)
    + labs(y="Matriculados")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

```
<ipython-input-19-f525ba1a46f4>:4: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-
```

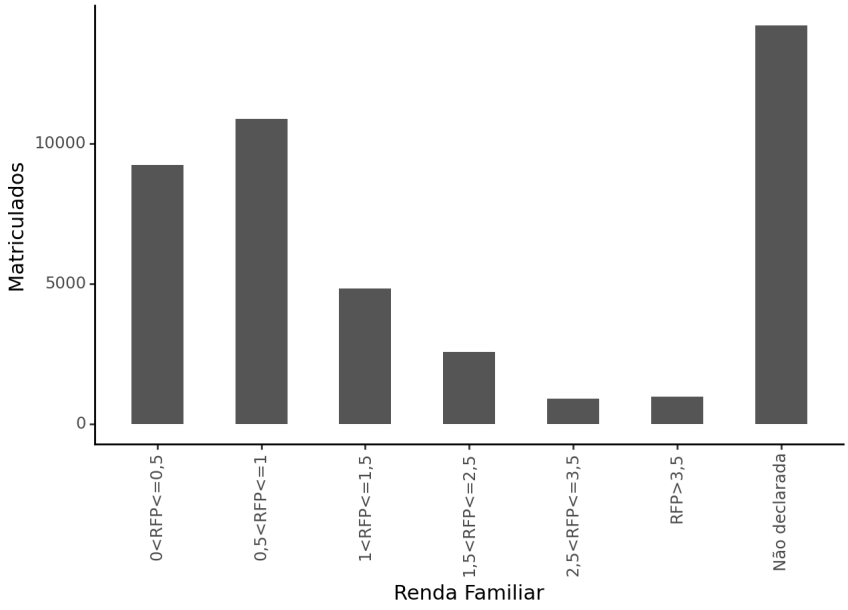


```
<Figure Size: (640 x 480)>
```

Notamos que o maior número de matriculados estão nas duas primeiras faixas de RFP.
Para nossos estudos teremos que remover os registros cujas matrículas não tenham declarada sua renda familiar.

```
df_filtered = df_filtered[ ~df_filtered['Renda Familiar'].isin(['Não declarada']) ]
df_filtered.shape
```

```
(29406, 18)
```

Renda Familiar - Legenda

RFP: Renda familiar per capita. É um valor utilizado pelo governo para comprovação de participação dos programas do governo federal. É calculado com base na soma da renda de todos os moradores de uma residência, dividida pelo número total de pessoas que vivem sob manutenção desta renda total.

Os agrupamentos utilizados no dataset são:

RFP	Descrição
0<RFP<=0,5	renda entre R$ 0,00 e R$ 500,00 por pessoa
0,5<RFP<=1	renda entre R$ 500,00 e R$ 1.000,00 por pessoa
1<RFP<=1,5	renda entre R$ 1.000,00 e R$ 1.500,00 por pessoa
1,5<RFP<=2,5	renda entre R$ 1.500,00 e R$ 2.500,00 por pessoa
2,5<RFP<=3,5	renda entre R$ 2.500,00 e R$ 3.500,00 por pessoa
RFP>3,5	renda acima de R$ 3.500,00 por pessoa

```
#Faixa Etária

(
    ggplot(df_filtered, aes(x="Faixa Etária"))
    + geom_histogram(binwidth=0.5, show_legend=True)
    + labs(y="Matriculados")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

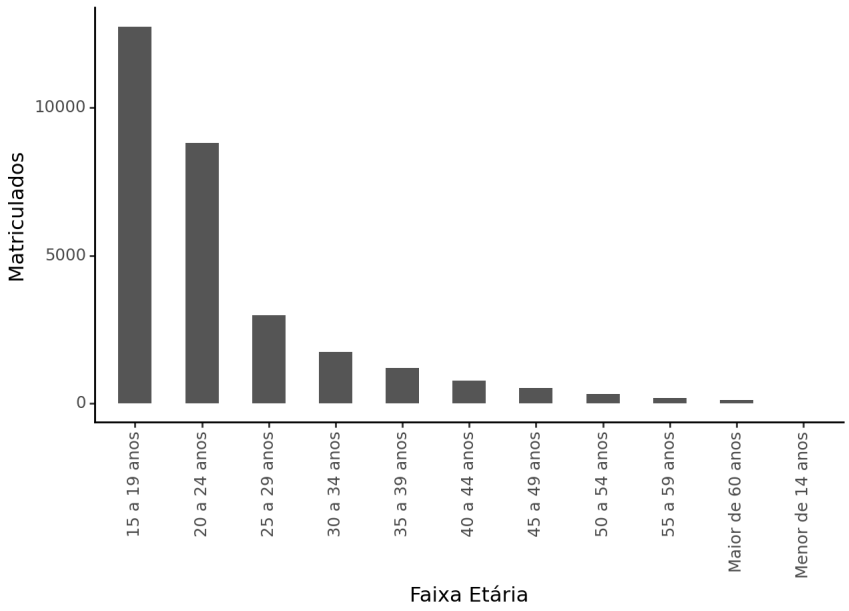


```
<Figure Size: (640 x 480)>
```

No gráfico acima podemos notar que o maior número de matriculados estão em faixas de idades que provavelmente estão fora do mercado de trabalho ou no início de suas carreiras e podem ter uma dependência maior da renda da família.

```
#Cor/Raça

(
    ggplot(df_filtered, aes(x="Cor/Raça"))
    + geom_histogram(binwidth=0.5, show_legend=True)
    + labs(y="Matriculados")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

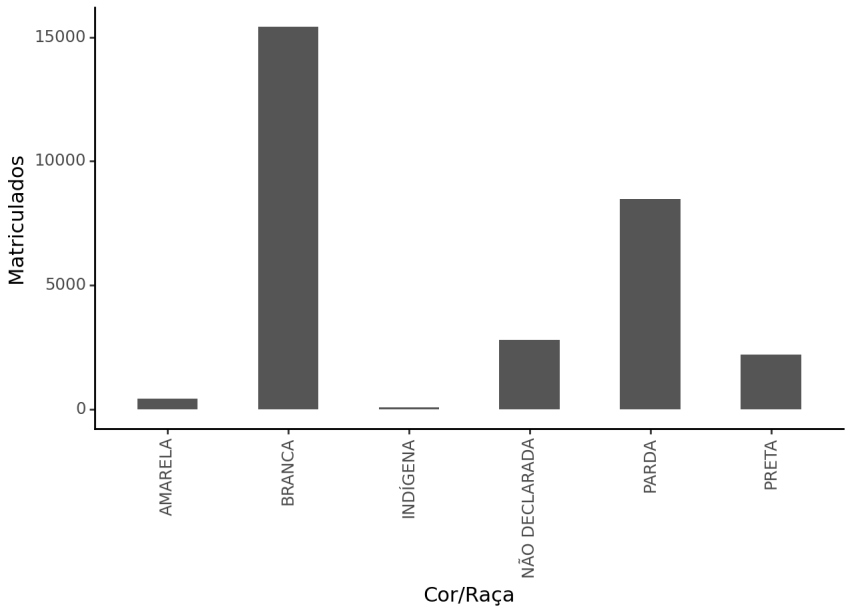


```
<Figure Size: (640 x 480)>
```

```
#Sexo

gender = df_filtered["Sexo"].value_counts()

# Customize colors and other settings
colors = ['#6488EA','#c22d6d']
explode = (0.01,0) # Explode 1st slice
plt.pie(gender, explode = explode, labels = ["Masculino", "Feminino"], colors = colors, autopct = '%1.1f%%', shadow = False,
plt.title('Matrículas por Sexo')
plt.axis('equal')
plt.show()
```

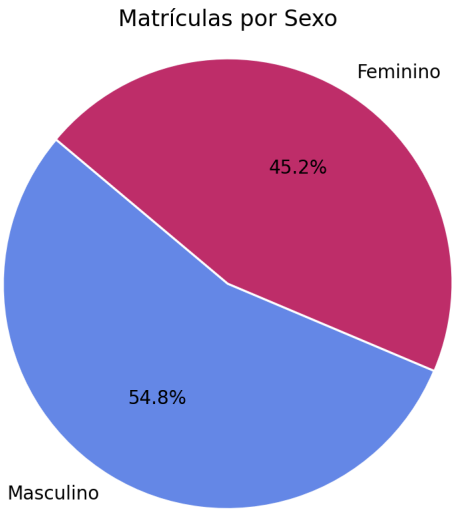


```
#Situaçao de Matricula

(
    ggplot(df_filtered, aes(x="Situação de Matrícula"))
    + geom_histogram(binwidth=0.5, show_legend=True)
    + labs(y="Matriculados")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

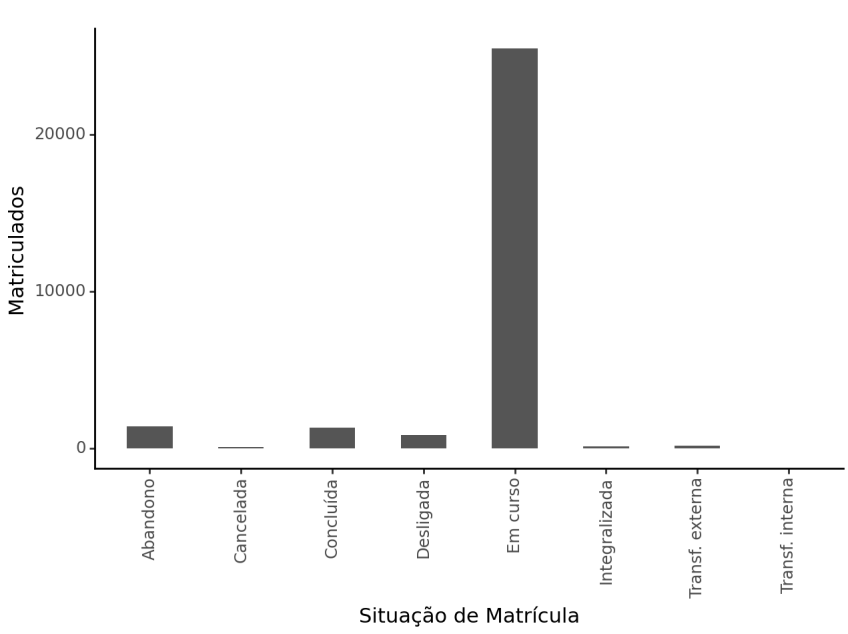


```
<Figure Size: (640 x 480)>
```

E por fim, os totais por Situação de Matrícula, onde podemos notar que o Abandono é a maior razão entre as situações que impedem os alunos de não concluirem um curso (Abandono, Cancelamento, Desligamento, Reprovação).

```
df_evaded = df_filtered[ df_filtered['Situação de Matrícula'].isin(['Abandono', 'Cancelada', 'Desligada', 'Transf. externa']
df_evaded.shape
```

```
(2460, 18)
```

```
df_concluded = df_filtered[ df_filtered['Situação de Matrícula'].isin(['Concluída']) ]
df_concluded.shape
```

```
(1326, 18)
```

3.2. ANÁLISE SOBRE OS DADOS DE EVASÃO

Evasão por: Tipo de Curso

```
#Matrículas por tipo de curso

(
    ggplot(df_evaded, aes(x="Tipo de Curso"))
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

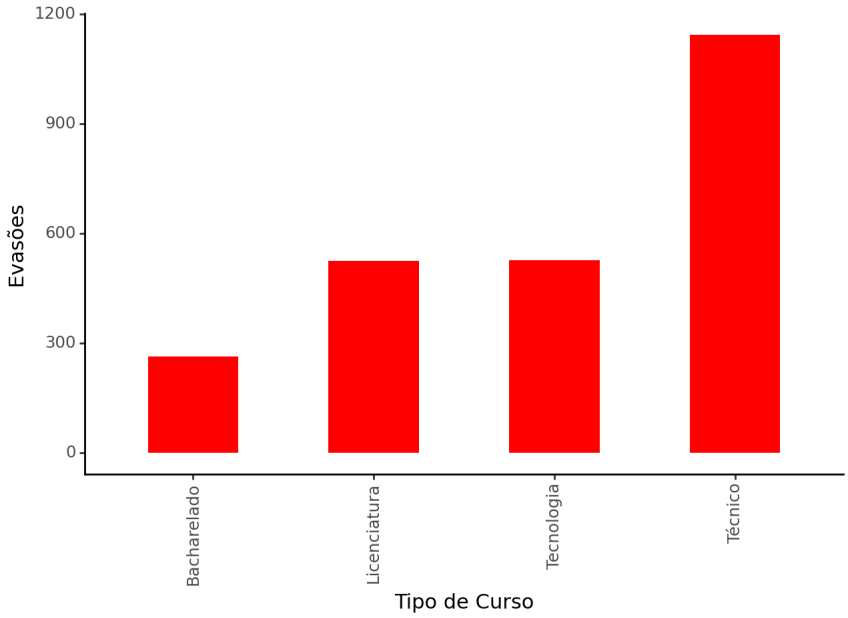


```
<Figure Size: (640 x 480)>
```

Evasão por: Renda Familiar

```
#Renda Familiar

(
    ggplot(df_evaded, aes(x="Renda Familiar"))
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

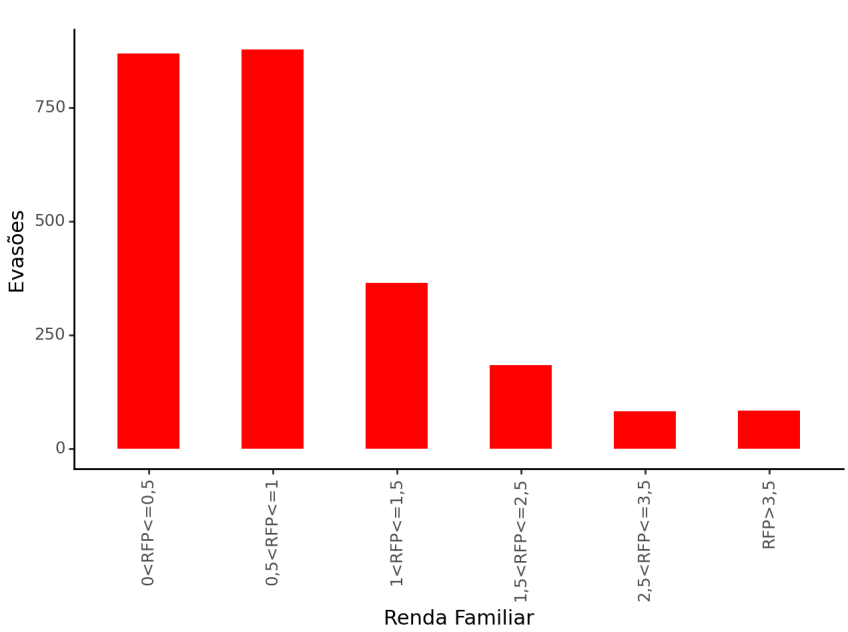


```
<Figure Size: (640 x 480)>
```

```
#Renda Familiar - dos alunos Concluintes

(
    ggplot(df_concluded, aes(x="Renda Familiar"))
    + geom_histogram(binwidth=0.5, show_legend=True, fill="green")
    + labs(y="Concluídos")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

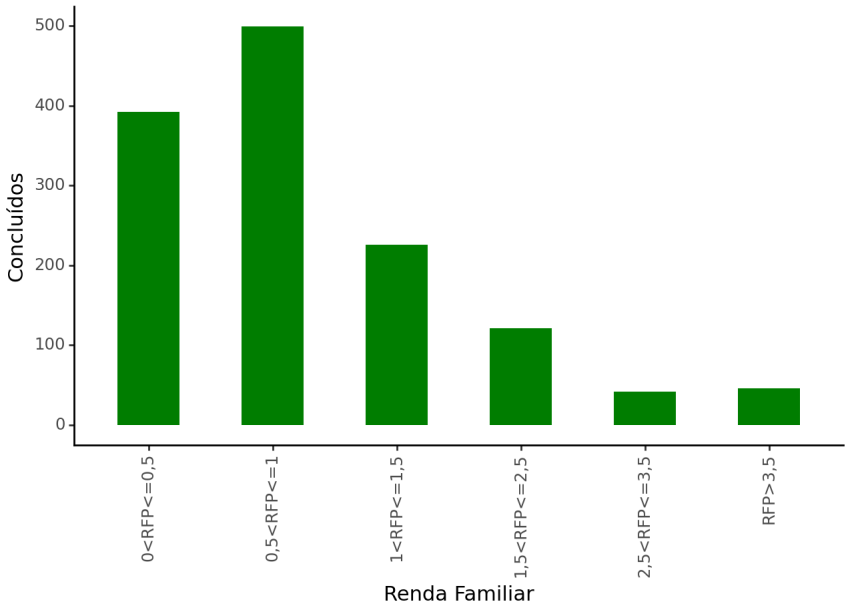


```
<Figure Size: (640 x 480)>
```

Evasão por: Faixa Etária

```
#Faixa Etária

(
    ggplot(df_evaded, aes(x="Faixa Etária"))
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

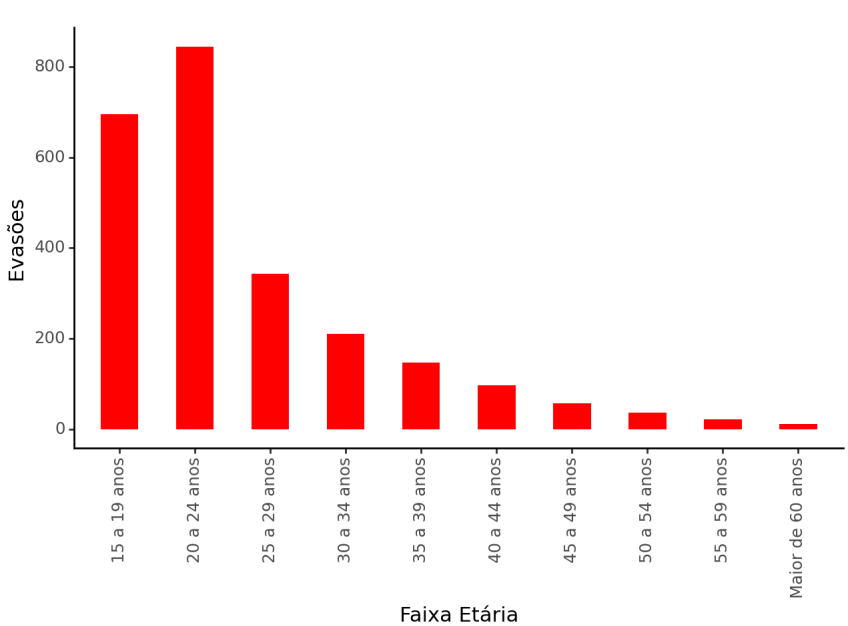


```
<Figure Size: (640 x 480)>
```

Evasão por: Cor/Raça

```
#Cor/Raça

(
    ggplot(df_evaded, aes(x="Cor/Raça"))
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

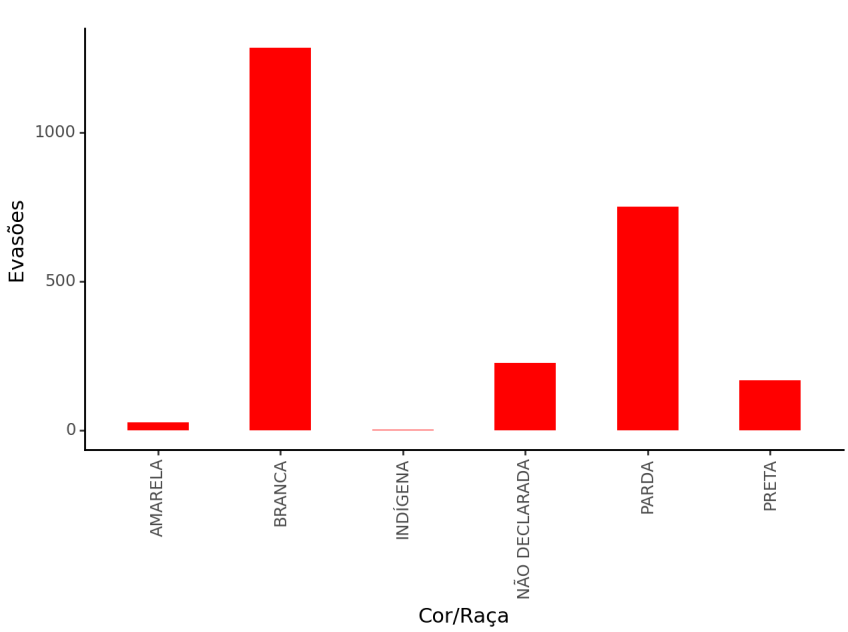


```
<Figure Size: (640 x 480)>
```

Evasão por: Sexo

```
#Sexo

gender = df_evaded["Sexo"].value_counts()

# Customize colors and other settings
colors = ['#6488EA','#c22d6d']
explode = (0.01,0) # Explode 1st slice
plt.pie(gender, explode = explode, labels = ["Masculino", "Feminino"], colors = colors, autopct = '%1.1f%%', shadow = False,
plt.title('Evasões por Sexo')
plt.axis('equal')
plt.show()
```

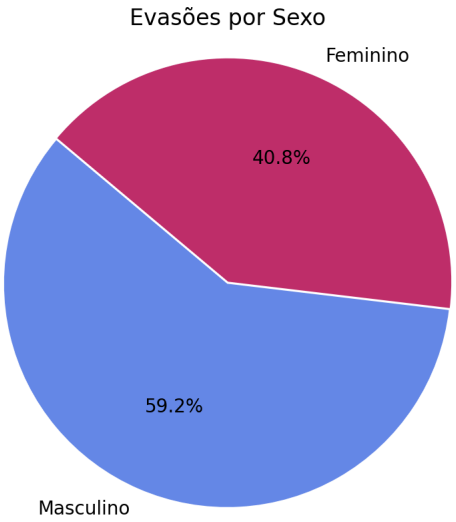

3.3. COMPARATIVO ENTRE DADOS DE EVASÃO E DADOS GERAIS DO IFSP

Matrículas/Evasão por: Tipo de Curso

```
#Matrículas por tipo de curso

(
    ggplot(df_evaded, aes(x="Tipo de Curso"))
    + geom_histogram(data=df_filtered, mapping=aes(x="Tipo de Curso"), binwidth=0.5, alpha=0.35, show_legend=True)
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Matrículas/Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

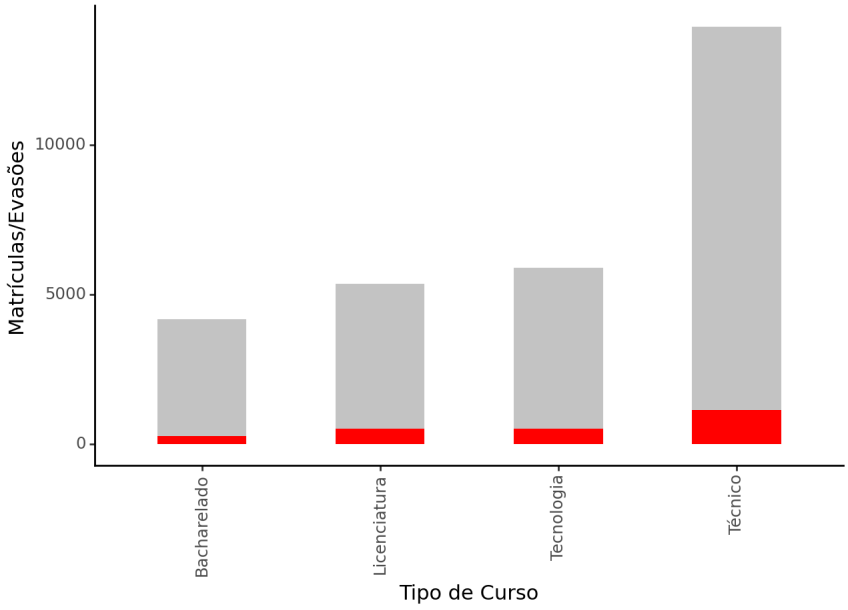


```
<Figure Size: (640 x 480)>
```

Matrículas/Evasão por: Renda Familiar

```
#Renda Familiar

(
    ggplot(df_evaded, aes(x="Renda Familiar"))
    + geom_histogram(data=df_filtered, mapping=aes(x="Renda Familiar"), binwidth=0.5, alpha=0.35, show_legend=True)
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Matrículas/Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

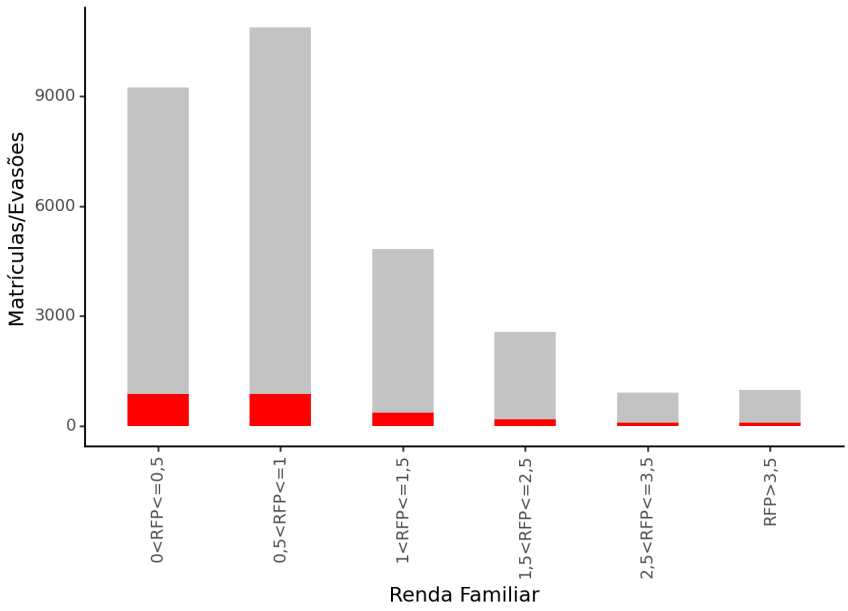


```
<Figure Size: (640 x 480)>
```

Matrículas/Evasão por: Faixa Etária

```
#Faixa Etária

(
    ggplot(df_evaded, aes(x="Faixa Etária"))
    + geom_histogram(data=df_filtered, mapping=aes(x="Faixa Etária"), binwidth=0.5, alpha=0.35, show_legend=True)
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Matrículas/Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

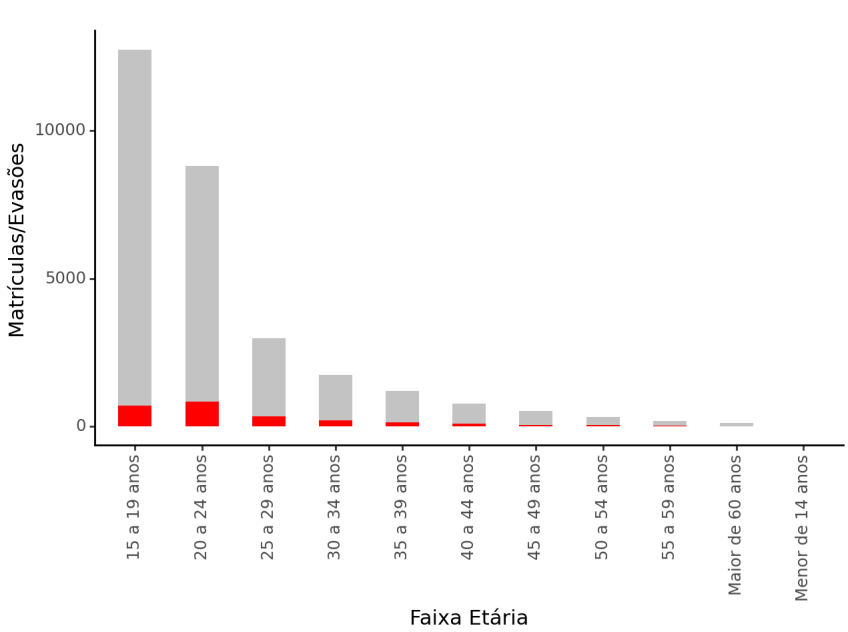


```
<Figure Size: (640 x 480)>
```

Matrículas/Evasão por: Cor/Raça

```
#Cor/Raça

(
    ggplot(df_evaded, aes(x="Cor/Raça"))
    + geom_histogram(data=df_filtered, mapping=aes(x="Cor/Raça"), binwidth=0.5, alpha=0.35, show_legend=True)
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Matrículas/Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

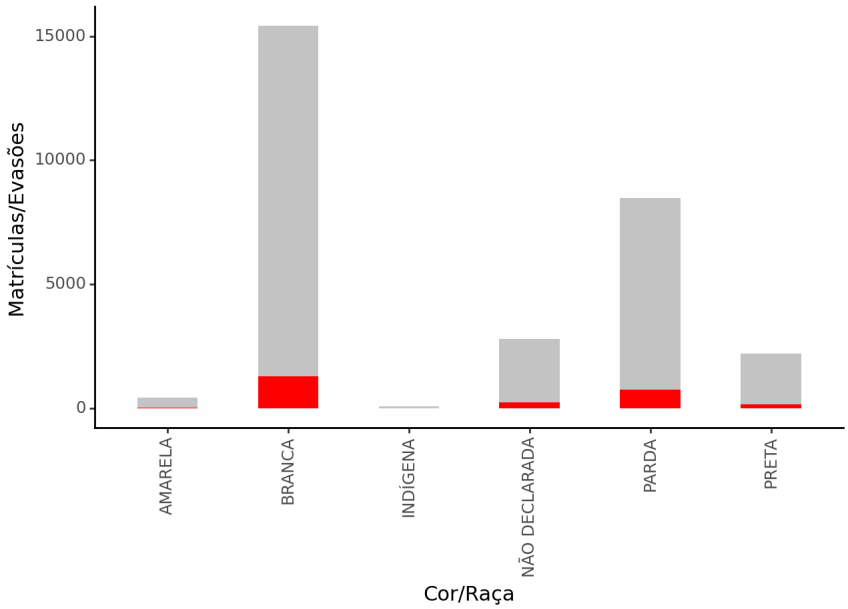


```
<Figure Size: (640 x 480)>
```

Matrículas/Evasão por: Sexo

```
#Sexo

(
    ggplot(df_evaded, aes(x="Sexo"))
    + geom_histogram(data=df_filtered, mapping=aes(x="Sexo"), binwidth=0.5, alpha=0.35, show_legend=True)
    + geom_histogram(binwidth=0.5, show_legend=True, fill="red")
    + labs(y="Matrículas/Evasões")
    + theme_classic()
    + theme(axis_text_x = element_text(angle=90))
)
```

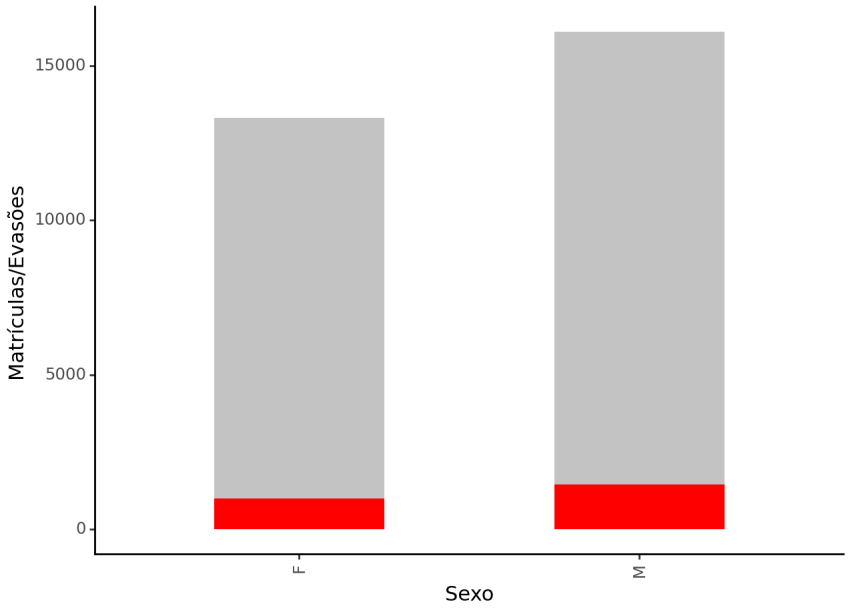


```
<Figure Size: (640 x 480)>
```

Teste de Hipóteses - Qui-Quadrada

```
# Adicionar a coluna de evasão binária
df_filtered['Evasao'] = df_filtered['Situação de Matrícula'].apply(lambda x: "Evadido" if x in ['Abandono', 'Cancelada', 'De
```

```
<ipython-input-38-531720e99ade>:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-
```

```
chi = pd.crosstab(df_filtered["Renda Familiar"], df_filtered["Evasao"])
chi
```

Renda Familiar	Evasao Evadido	Não Evadido
0<RFP<=0,5	809	8432
0,5<RFP<=1	812	10068
1<RFP<=1,5	352	4485
1,5<RFP<=2,5	173	2389
2,5<RFP<=3,5	78	833
RFP>3,5	77	898

Próximas etapas: Gerar código com chi | Ver gráficos recomendados

```
# Cálculo do Qui-Quadrado a partir da tabela de contingência
chi_scores = chi2_contingency(chi)
chi_scores
```

```
Chi2ContingencyResult(statistic=19.833609589805565, pvalue=0.0013428318862340307, dof=5, expected_freq=array([[
723.10212202,  8517.89787798],
       [  851.35278515, 10028.64721485],
       [  378.49204244,  4458.50795756],
       [  200.47480106,  2361.52519894],
       [   71.28514589,   839.71485411],
       [   76.29310345,   898.70689655]]))
```

```
def qui_quadrado(df, variavel, lista):

  # Calcular Qui2 e p-valor para cada variável e colocar resultado num df
  d = {'Qui2': [], 'p-Valor': []}

  for l in lista:

      # Cria tabela que relaciona variável com lista
      tab = pd.crosstab(df[variavel], df[l])

      # Calcula o qui2 entre as duas variáveis
      chi_scores = chi2_contingency(tab)

      # Recupera o valor e p-value do teste
      scores = pd.Series(chi_scores[0])
      pvalues = pd.Series(chi_scores[1])

      # Adiciona resultado ao dicionário
      d['Qui2'].append(scores[0])
      d['p-Valor'].append(pvalues[0])

  # Transformar dicionário em dataframe
  chi_squared = pd.DataFrame(d)

  # Formato de visualização dos números
  pd.options.display.float_format = "{:,.2f}".format

  # Renomear linhas do df
  for n, l in zip(np.arange(0, len(lista), 1), lista[0:len(lista)]):
    chi_squared = chi_squared.rename(index = {n: l})

  # Mostrar em ordem crescente para o p-valor
  chi_squared = chi_squared.sort_values(by = 'p-Valor', ascending = True)

  # Visualizar df
  return chi_squared


vars = ['Renda Familiar', 'Cor/Raça', 'Faixa Etária', 'Sexo', 'Tipo de Curso']

qui_quadrado(df_filtered, "Evasao", vars)
```

	Qui2	p-Valor
Faixa Etária	381.25	0.00
Tipo de Curso	52.07	0.00
Sexo	28.61	0.00
Renda Familiar	19.83	0.00
Cor/Raça	7.77	0.17

```
def analise_bi(df, var1, var2, ordem_linhas, ordem_colunas):

    df_group = df.groupby([var1, var2])[var2].count().unstack(var2).fillna(0)

    df_group = df_group.reindex(ordem_linhas)

    # Reordenar colunas
    df_group = df_group[ordem_colunas]

    return df_group
```

```
def barras_empilhadas_porcentagem(df_group, titulo, barWidth = 0.75):

    if len(df_group.columns) == 2:

        total = [ i+j for i, j in zip(df_group.iloc[:,0], df_group.iloc[:,1])]
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]

        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#F54337', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#446BC4', edgecolor = 'white', width = barWidth, label = df_group.columns[1


    elif len(df_group.columns) == 3:

        total = [ i+j+k for i, j, k in zip(df_group.iloc[:,0], df_group.iloc[:,1], df_group.iloc[:,2])]
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]
        bar3 = [ i / j * 100 for i, j in zip(df_group.iloc[:,2], total)]

        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#FFCC00', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#F39000', edgecolor = 'white', width = barWidth, label = df_group.columns[1
        # Barra 3
        plt.bar(r, bar3, bottom = [i+j for i, j in zip(bar1, bar2)], color = '#F54337', edgecolor = 'white', width = barWidt

    elif len(df_group.columns) == 4:

        total = [ i+j+k+l for i, j, k, l in zip(df_group.iloc[:,0], df_group.iloc[:,1], df_group.iloc[:,2], df_group.iloc[:,
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]
        bar3 = [ i / j * 100 for i, j in zip(df_group.iloc[:,2], total)]
        bar4 = [ i / j * 100 for i, j in zip(df_group.iloc[:,3], total)]

        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#FFCC00', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#F39000', edgecolor = 'white', width = barWidth, label = df_group.columns[1
        # Barra 3
        plt.bar(r, bar3, bottom = [i+j for i, j in zip(bar1, bar2)], color = '#F54337', edgecolor = 'white', width = barWidt
        # Barra 4
        plt.bar(r, bar4, bottom = [i+j+k for i, j, k in zip(bar1, bar2, bar3)], color = '#8C0046', edgecolor = 'white', widt

    elif len(df_group.columns) == 5:

        total = [ i+j+k+l+m for i, j, k, l, m in zip(df_group.iloc[:,0], df_group.iloc[:,1], df_group.iloc[:,2], df_group.il
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]
        bar3 = [ i / j * 100 for i, j in zip(df_group.iloc[:,2], total)]
        bar4 = [ i / j * 100 for i, j in zip(df_group.iloc[:,3], total)]
        bar5 = [ i / j * 100 for i, j in zip(df_group.iloc[:,4], total)]

        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#FFCC00', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#F39000', edgecolor = 'white', width = barWidth, label = df_group.columns[1
        # Barra 3
        plt.bar(r, bar3, bottom = [i+j for i, j in zip(bar1, bar2)], color = '#F54337', edgecolor = 'white', width = barWidt
        # Barra 4
        plt.bar(r, bar4, bottom = [i+j+k for i, j, k in zip(bar1, bar2, bar3)], color = '#8C0046', edgecolor = 'white', widt
        # Barra 5
        plt.bar(r, bar5, bottom = [i+j+k+l for i, j, k, l in zip(bar1, bar2, bar3, bar4)], color = '#446BC4', edgecolor = 'w

    elif len(df_group.columns) == 6:

        total = [ i+j+k+l+m+n for i, j, k, l, m, n in zip(df_group.iloc[:,0], df_group.iloc[:,1], df_group.iloc[:,2], df_grc
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]
        bar3 = [ i / j * 100 for i, j in zip(df_group.iloc[:,2], total)]
        bar4 = [ i / j * 100 for i, j in zip(df_group.iloc[:,3], total)]
        bar5 = [ i / j * 100 for i, j in zip(df_group.iloc[:,4], total)]
        bar6 = [ i / j * 100 for i, j in zip(df_group.iloc[:,5], total)]
```

```
        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#FFCC00', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#F39000', edgecolor = 'white', width = barWidth, label = df_group.columns[1
        # Barra 3
        plt.bar(r, bar3, bottom = [i+j for i, j in zip(bar1, bar2)], color = '#F54337', edgecolor = 'white', width = barWidt
        # Barra 4
        plt.bar(r, bar4, bottom = [i+j+k for i, j, k in zip(bar1, bar2, bar3)], color = '#8C0046', edgecolor = 'white', widt
        # Barra 5
        plt.bar(r, bar5, bottom = [i+j+k+l for i, j, k, l in zip(bar1, bar2, bar3, bar4)], color = '#446BC4', edgecolor = 'w
        # Barra 6
        plt.bar(r, bar6, bottom = [i+j+k+l+m for i, j, k, l, m in zip(bar1, bar2, bar3, bar4, bar5)], color = '#009EBF', edg

    elif len(df_group.columns) == 7:

        total = [ i+j+k+l+m+n+o for i, j, k, l, m, n, o in zip(df_group.iloc[:,0], df_group.iloc[:,1], df_group.iloc[:,2], d
        bar1 = [ i / j * 100 for i, j in zip(df_group.iloc[:,0], total)]
        bar2 = [ i / j * 100 for i, j in zip(df_group.iloc[:,1], total)]
        bar3 = [ i / j * 100 for i, j in zip(df_group.iloc[:,2], total)]
        bar4 = [ i / j * 100 for i, j in zip(df_group.iloc[:,3], total)]
        bar5 = [ i / j * 100 for i, j in zip(df_group.iloc[:,4], total)]
        bar6 = [ i / j * 100 for i, j in zip(df_group.iloc[:,5], total)]
        bar7 = [ i / j * 100 for i, j in zip(df_group.iloc[:,6], total)]

        r = df_group.index

        # Barra 1
        plt.bar(r, bar1, color = '#FFCC00', edgecolor = 'white', width = barWidth, label = df_group.columns[0])
        # Barra 2
        plt.bar(r, bar2, bottom = bar1, color = '#F39000', edgecolor = 'white', width = barWidth, label = df_group.columns[1
        # Barra 3
        plt.bar(r, bar3, bottom = [i+j for i, j in zip(bar1, bar2)], color = '#F54337', edgecolor = 'white', width = barWidt
        # Barra 4
        plt.bar(r, bar4, bottom = [i+j+k for i, j, k in zip(bar1, bar2, bar3)], color = '#8C0046', edgecolor = 'white', widt
        # Barra 5
        plt.bar(r, bar5, bottom = [i+j+k+l for i, j, k, l in zip(bar1, bar2, bar3, bar4)], color = '#446BC4', edgecolor = 'w
        # Barra 6
        plt.bar(r, bar6, bottom = [i+j+k+l+m for i, j, k, l, m in zip(bar1, bar2, bar3, bar4, bar5)], color = '#009EBF', edg
        # Barra 7
        plt.bar(r, bar7, bottom = [i+j+k+l+m+n for i, j, k, l, m, n in zip(bar1, bar2, bar3, bar4, bar5, bar6)], color = '#2

    else:
        return print('Número de categorias inválido')

    # Linha horizontal
    plt.axhline(linewidth = 2, color = 'black')

    # Adicionar titulo
    plt.title(titulo, fontsize = 16, pad = 20);

    # Adicionar legenda
    plt.legend(loc = 'lower center', bbox_to_anchor = (0.5, -0.17), ncol = 3, frameon = False)

    # Remover eixo y
    plt.yticks([])

    # Remover ticks
    plt.tick_params(left = False)
    plt.tick_params(bottom = False)

    # Alterar tamanho e salvar gráfico
    fig = plt.gcf()
    fig.set_size_inches(13, 8)

    # Mostrar gráfico
    plt.show()


var1 = 'Evasao'
var2 = 'Renda Familiar'

ordem_linhas = ['Não Evadido', 'Evadido']
ordem_colunas = ['0<RFP<=0,5', '0,5<RFP<=1', '1<RFP<=1,5', '1,5<RFP<=2,5', '2,5<RFP<=3,5', 'RFP>3,5']

rank_Evasao = analise_bi(df_filtered, var1, var2, ordem_linhas, ordem_colunas)
titulo = 'Evasão por Renda Familiar'

barras_empilhadas_porcentagem(rank_Evasao, titulo)
```

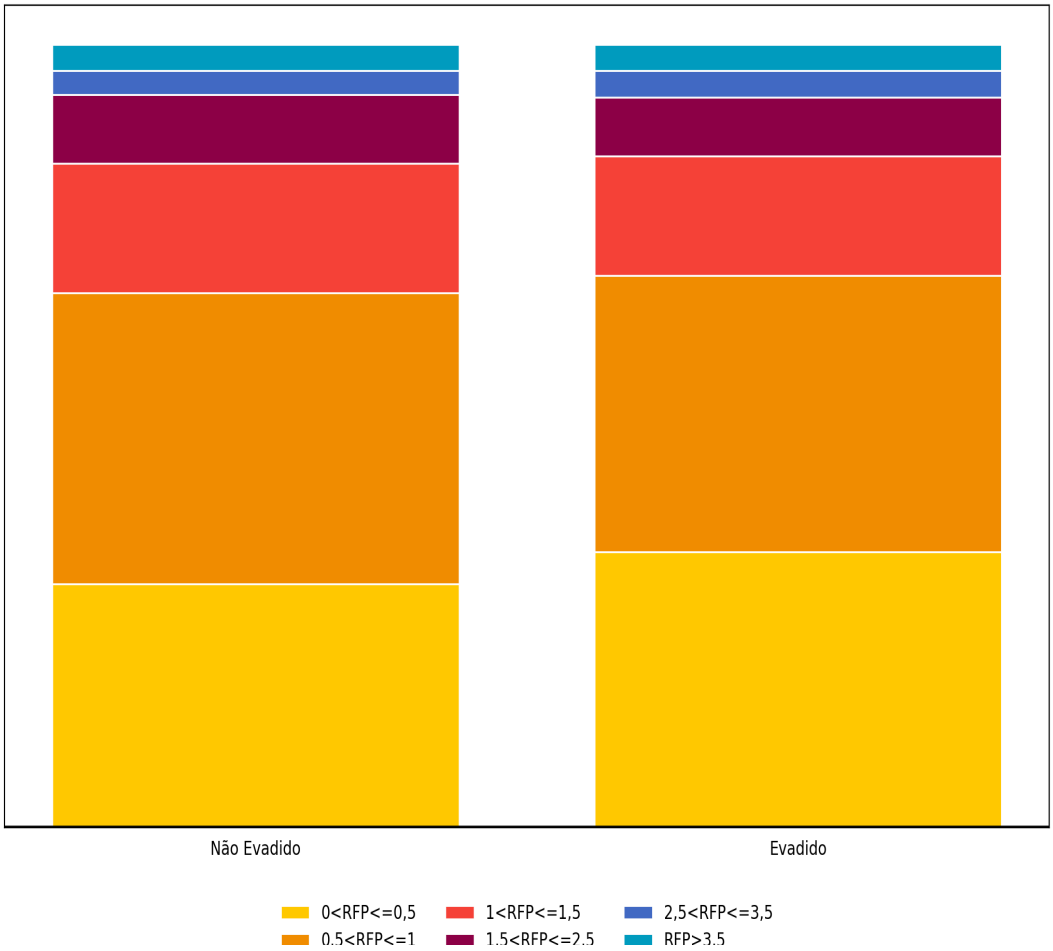


```
var1 = 'Evasao'
var2 = 'Sexo'

ordem_linhas = ['Não Evadido', 'Evadido']
ordem_colunas = ['F', 'M']

rank_Sexo = analise_bi(df_filtered, var1, var2, ordem_linhas, ordem_colunas)
titulo = 'Evasão por Sexo'

barras_empilhadas_porcentagem(rank_Sexo, titulo)
```

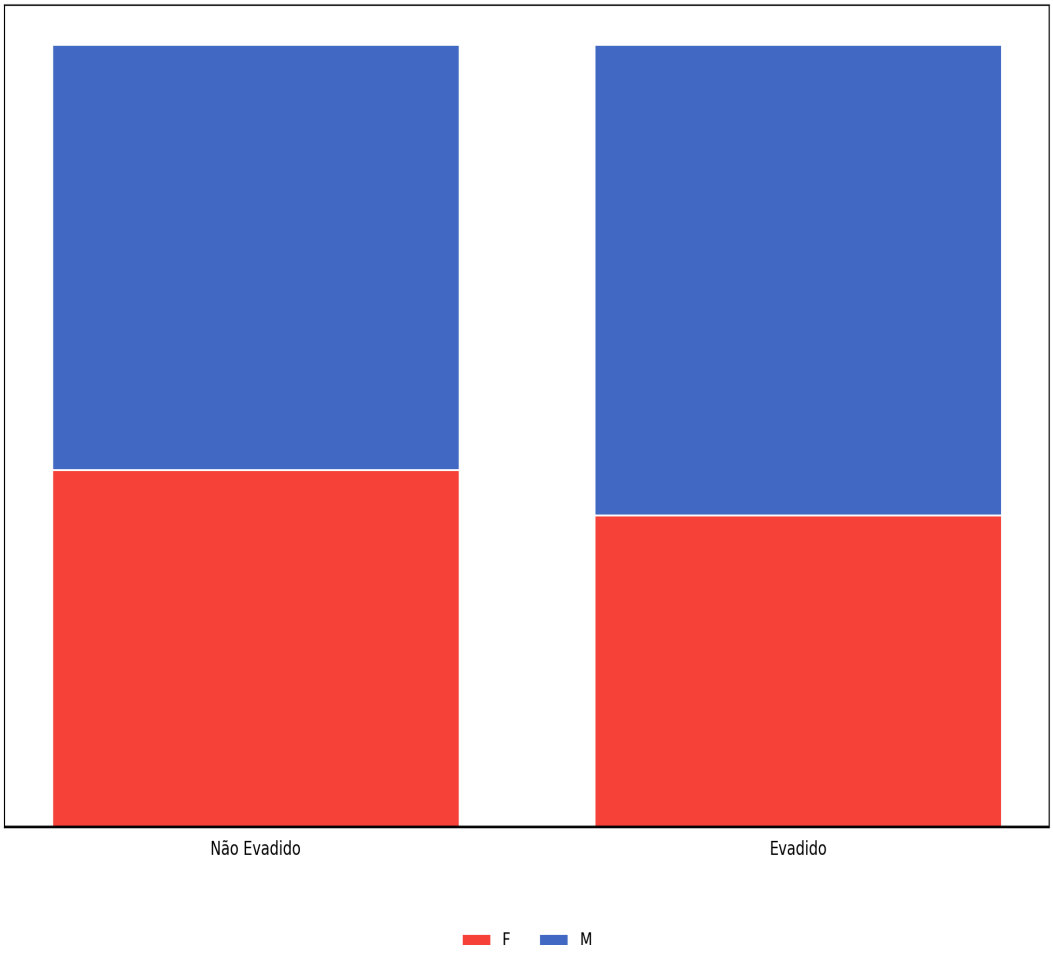


```
var1 = 'Evasao'
var2 = 'Cor/Raça'

ordem_linhas = ['Não Evadido', 'Evadido']
ordem_colunas = ['AMARELA', 'BRANCA', 'INDÍGENA', 'PARDA', 'PRETA', 'NÃO DECLARADA' ]

rank_Raca = analise_bi(df_filtered, var1, var2, ordem_linhas, ordem_colunas)
titulo = 'Evasão por Cor/Raça'

barras_empilhadas_porcentagem(rank_Raca, titulo)
```

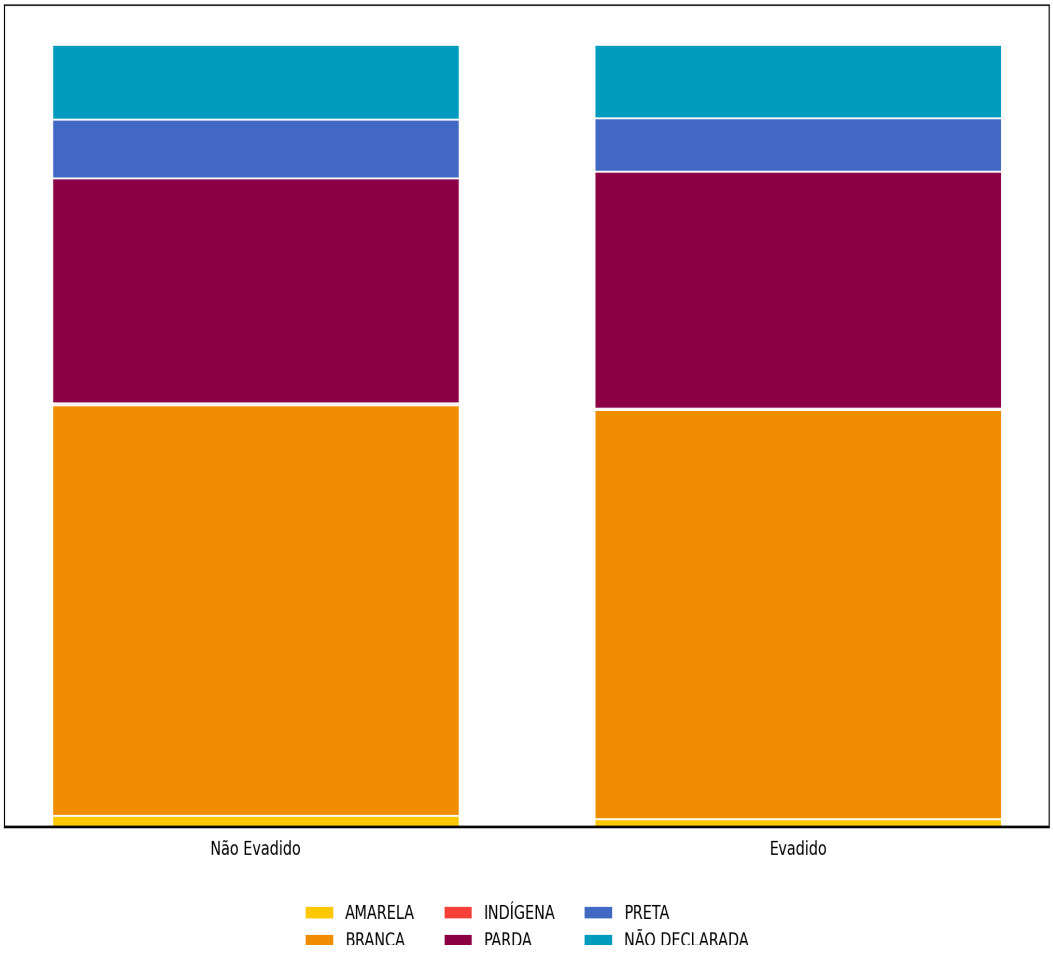


```
var1 = 'Evasao'
var2 = 'Faixa Etária'

ordem_linhas = ['Não Evadido', 'Evadido']
ordem_colunas = ['15 a 19 anos', '20 a 24 anos', '25 a 29 anos', '30 a 34 anos', '35 a 39 anos', '50 a 54 anos', '45 a 49 ar

rank_Idade = analise_bi(df_filtered, var1, var2, ordem_linhas, ordem_colunas)
titulo = 'Evasão por Faixa Etaria'

barras_empilhadas_porcentagem(rank_Idade, titulo)
```

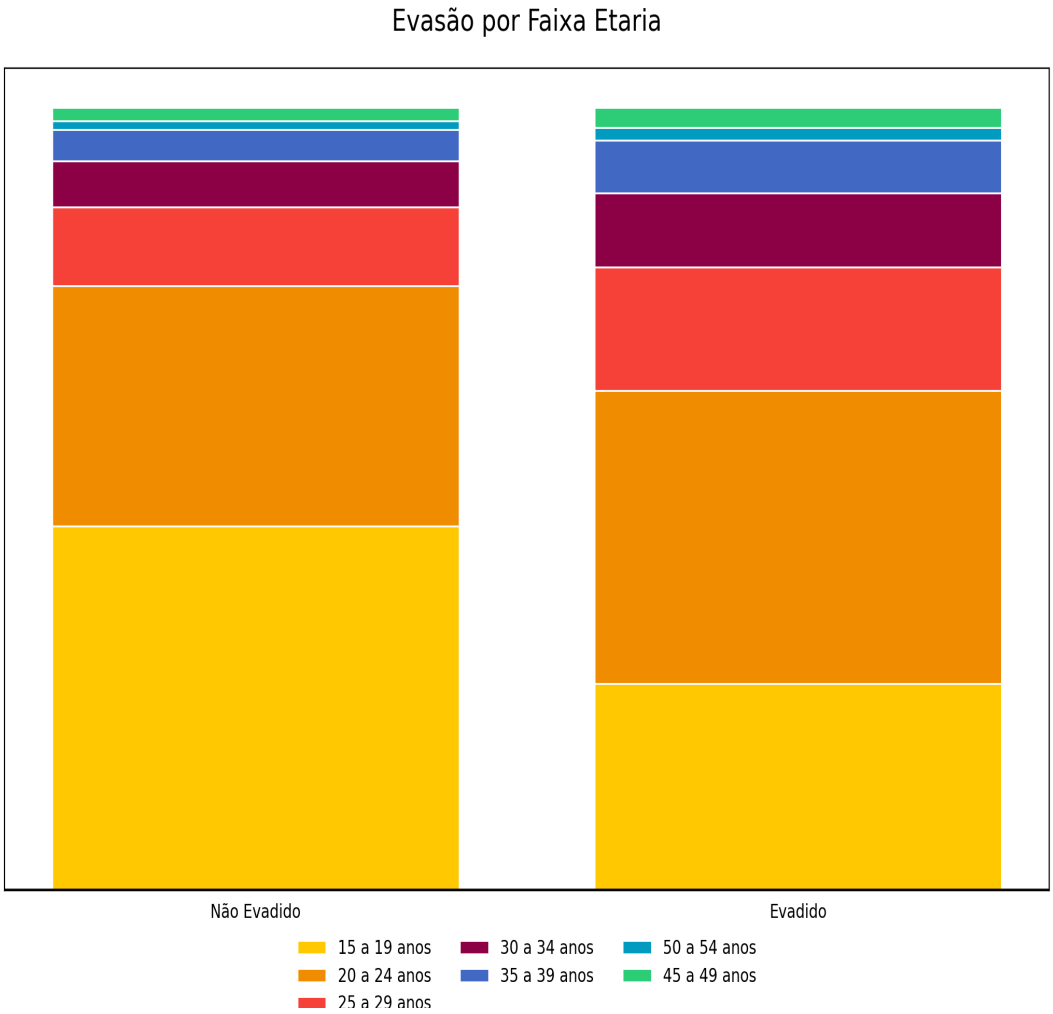


```
var1 = 'Evasao'
var2 = 'Tipo de Curso'

ordem_linhas = ['Não Evadido', 'Evadido']
ordem_colunas = ['Bacharelado', 'Licenciatura', 'Técnico', 'Tecnologia']

rank_Curso = analise_bi(df_filtered, var1, var2, ordem_linhas, ordem_colunas)
titulo = 'Evasão por Tipo de Curso'

barras_empilhadas_porcentagem(rank_Curso, titulo)
```

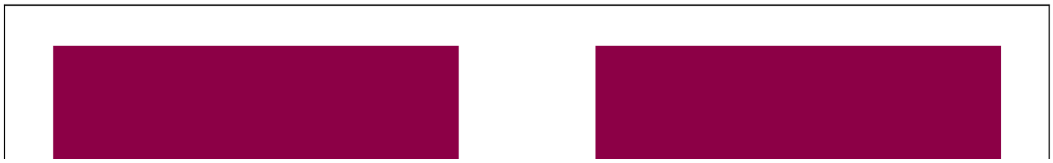
Evasão por Tipo de Curso